

UNIVERSIDADE FEDERAL DO RIO GRANDE

Antonio Davi Araújo dos Santos

**Predição de Tendências em Ações do Mercado
Brasileiro Utilizando Redes Neurais LSTM
Universidade Federal do Rio Grande**

Brasil

2026

UNIVERSIDADE FEDERAL DO RIO GRANDE

Antonio Davi Araújo dos Santos

**Predição de Tendências em Ações do Mercado Brasileiro
Utilizando Redes Neurais LSTM
Universidade Federal do Rio Grande**

Trabalho acadêmico apresentado ao Curso de Engenharia de Computação da Universidade Federal do Rio Grande como requisito parcial para a obtenção do grau de Bacharel em Engenharia de Computação.

Orientador: Rafael Alceste Berri

Universidade Federal do Rio Grande – FURG

Centro de Ciências Computacionais

Curso de Engenharia de Computação

Brasil

2026

Resumo

Este trabalho apresenta uma proposta para a predição de tendências em ações do mercado brasileiro utilizando redes neurais LSTM. A pesquisa parte da dificuldade de prever séries temporais financeiras, que apresentam características como volatilidade, ruído, não estacionariedade e influência de fatores externos. Em vez de buscar prever diretamente o preço futuro de uma ação, o trabalho formula o problema como uma tarefa de classificação multiclasse, na qual os movimentos futuros dos ativos são classificados em alta, baixa ou estabilidade. A metodologia proposta envolve a seleção de ativos negociados na B3, incluindo ações que compõem o Ibovespa e o ETF BOVA11, a coleta de dados históricos em frequência diária, o pré-processamento das séries financeiras, a construção de janelas temporais deslizantes, a rotulagem das tendências com base na variação percentual do preço de fechamento e o treinamento de uma rede neural LSTM. O desempenho do modelo será avaliado por meio de métricas de classificação, como acurácia, precisão, recall, F1-score e matriz de confusão. Espera-se, com este trabalho, verificar a viabilidade da aplicação de uma arquitetura LSTM simples na classificação de tendências em ações brasileiras, contribuindo para a discussão acadêmica sobre o uso de aprendizado profundo em séries temporais financeiras do mercado nacional.

Palavras-chave: Predição de tendências; Mercado de ações brasileiro; Redes neurais LSTM; Aprendizado profundo; Séries temporais financeiras.

Abstract

This work presents a proposal for stock trend prediction in the Brazilian stock market using LSTM neural networks. The research is based on the difficulty of forecasting financial time series, which are characterized by volatility, noise, non-stationarity, and the influence of external factors. Instead of directly predicting the future price of a stock, this work formulates the problem as a multiclass classification task, in which future asset movements are classified as upward, downward, or stable. The proposed methodology involves the selection of assets traded on B3, including stocks that compose the Ibovespa index and the BOVA11 ETF, the collection of daily historical data, the preprocessing of financial time series, the construction of sliding time windows, the labeling of trends based on the percentage variation of closing prices, and the training of an LSTM neural network. The model performance will be evaluated using classification metrics such as accuracy, precision, recall, F1-score, and confusion matrix. This work is expected to verify the feasibility of applying a simple LSTM architecture to classify trends in Brazilian stocks, contributing to the academic discussion on the use of deep learning in financial time series in the Brazilian market. It is emphasized that the objective of this work is not to propose an investment strategy or financial recommendation, but to conduct an experimental evaluation of the application of neural networks to trend prediction.

Keywords: Trend prediction; Brazilian stock market; LSTM neural networks; Deep learning; Financial time series.

Lista de ilustrações

Figura 1 – Representação simplificada dos dados OHLCV: (a) preços OHLC em gráfico de candles e (b) volume negociado.	24
Figura 2 – Representação simplificada de uma célula LSTM.	29
Figura 3 – Diagrama da metodologia utilizada.	47

Lista de tabelas

Tabela 1 – Objetivos e mercados dos trabalhos relacionados.	40
Tabela 2 – Dados utilizados nos trabalhos relacionados.	41
Tabela 3 – Técnicas empregadas nos trabalhos relacionados.	42
Tabela 4 – Métodos, métricas e horizontes de predição.	43
Tabela 5 – Resultados, limitações e aplicabilidade.	44
Tabela 6 – Cronograma das atividades.	57

Lista de abreviaturas e siglas

B3	Brasil, Bolsa, Balcão
CNN	Convolutional Neural Network
DNN	Deep Neural Network
ETF	Exchange Traded Fund
GRU	Gated Recurrent Unit
IA	Inteligência Artificial
LSTM	Long Short-Term Memory
MACD	Moving Average Convergence Divergence
ML	Machine Learning
OHLC	Open, High, Low and Close
OHLCV	Open, High, Low, Close and Volume
RNN	Recurrent Neural Network
RSI	Relative Strength Index
SVM	Support Vector Machine

Lista de símbolos

N	Tamanho da janela temporal
$\%$	Percentual de variação do preço
x_t	Entrada no instante atual
h_{t-1}	Estado oculto anterior
h_t	Estado oculto no instante atual
C_{t-1}	Estado de memória anterior
C_t	Estado de memória no instante atual
f_t	Porta de esquecimento da célula LSTM
i_t	Porta de entrada da célula LSTM
$\tilde{C}_t$	Estado candidato da célula LSTM
o_t	Porta de saída da célula LSTM
$\tanh$	Função tangente hiperbólica

Sumário

1	INTRODUÇÃO	17
1.1	Motivação	18
1.2	Objetivos	18
1.2.1	Objetivo geral	19
1.2.2	Objetivos específicos	19
1.3	Justificativa	19
1.4	Estrutura do trabalho	20
2	FUNDAMENTAÇÃO TEÓRICA	23
2.1	Mercado de ações e séries temporais financeiras	23
2.1.1	Predição de tendência em ações	25
2.2	Aprendizado de máquina	26
2.2.1	Redes neurais artificiais	27
2.2.1.1	Redes neurais recorrentes	28
2.2.1.1.1	Redes LSTM	28
2.2.2	Pré-processamento, normalização e janelas temporais	30
2.2.3	Classificação multiclasse de tendências	31
2.2.4	Métricas de avaliação para classificação	32
2.3	Considerações finais do capítulo	33
3	TRABALHOS RELACIONADOS	35
3.1	Método de Seleção	35
3.2	Análise dos Trabalhos Relacionados	36
3.3	Considerações Finais do Capítulo	45
4	METODOLOGIA	47
4.1	Seleção dos ativos e coleta dos dados	48
4.2	Pré-processamento dos dados	48
4.3	Construção das entradas do modelo	49
4.4	Rotulagem das tendências	49
4.5	Divisão dos dados	50
4.6	Modelo LSTM	50
4.7	Treinamento do modelo	51
4.8	Predição e avaliação dos resultados	51
4.9	Síntese da metodologia	52

5	RESULTADOS ESPERADOS	53
5.1	Organização e preparação dos dados	53
5.2	Rotulagem das tendências	53
5.3	Desempenho do modelo LSTM	54
5.4	Análise da viabilidade da abordagem	54
5.5	Limitações esperadas	55
6	CRONOGRAMA	57
7	CONSIDERAÇÕES FINAIS	59
	REFERÊNCIAS	61

1 Introdução

O mercado de ações é um ambiente caracterizado pela negociação de ativos financeiros, como ações, fundos de índice e outros instrumentos de renda variável. No Brasil, esse mercado é organizado principalmente pela B3¹, bolsa responsável pela infraestrutura de negociação de ativos financeiros no país (B3, 2026d). Nesse contexto, as ações representam parcelas do capital social de empresas de capital aberto, permitindo que investidores participem dessas empresas por meio da compra e venda desses títulos (B3, 2026a).

A análise do comportamento desses ativos é relevante tanto para investidores quanto para pesquisadores, pois os preços das ações variam ao longo do tempo em função de fatores econômicos, políticos, setoriais e comportamentais. Essas variações formam séries temporais financeiras, que podem ser analisadas por meio de dados históricos, como preços de abertura, máxima, mínima, fechamento e volume negociado. Esses dados são amplamente utilizados em estudos de previsão e análise de mercado (TSAY, 2010).

Apesar da disponibilidade de dados históricos, a predição no mercado financeiro continua sendo uma tarefa complexa. As séries temporais financeiras apresentam características como volatilidade, ruído, não estacionariedade e influência de fatores externos, o que dificulta a identificação de padrões estáveis ao longo do tempo (TSAY, 2010). Por esse motivo, prever exatamente o preço futuro de uma ação pode ser uma tarefa bastante desafiadora.

Uma alternativa à previsão direta de preços é a predição de tendências. Nessa abordagem, o objetivo não é estimar o valor exato que uma ação terá no futuro, mas classificar a direção provável do seu movimento. Assim, o problema pode ser tratado como uma tarefa de classificação, na qual a saída do modelo indica se o ativo tende a apresentar movimento de alta, baixa ou estabilidade em determinado horizonte futuro. Essa formulação é utilizada em estudos de predição de tendência de preços, pois permite transformar variações futuras em classes interpretáveis (PRATA et al., 2024).

Nos últimos anos, técnicas de aprendizado de máquina e aprendizado profundo têm sido aplicadas à análise de séries temporais financeiras. Modelos de aprendizado profundo são capazes de aprender representações complexas dos dados, sendo úteis em problemas que envolvem relações não lineares e dependências temporais (GOODFELLOW; BENGIO; COURVILLE, 2016). Entre essas técnicas, destacam-se as redes neurais recorrentes, especialmente as redes LSTM, propostas para lidar com dependências de longo prazo em sequências (HOCHREITER; SCHMIDHUBER, 1997).

¹ Disponível em: <https://www.b3.com.br/pt_br/>. Acesso em: 5 jun. 2026.

Diante desse contexto, este trabalho propõe a aplicação de uma rede neural LSTM para a predição de tendências em ações do mercado brasileiro. A proposta consiste em utilizar dados históricos de ativos negociados na B3, organizar esses dados em janelas temporais, rotular os movimentos futuros em alta, baixa ou estabilidade e avaliar o desempenho do modelo por meio de métricas de classificação.

1.1 Motivação

A motivação deste trabalho está relacionada à importância da análise de tendências no mercado financeiro e ao crescimento do uso de técnicas de aprendizado profundo em problemas de séries temporais. A tomada de decisão no mercado de ações envolve incerteza, pois os preços dos ativos podem variar rapidamente em função de diferentes fatores. Nesse cenário, modelos computacionais podem contribuir para a identificação de padrões históricos e para a análise de possíveis movimentos futuros.

A predição de tendências se mostra relevante porque oferece uma forma mais interpretável de analisar o comportamento futuro de um ativo. Em vez de tentar prever exatamente o preço de uma ação, busca-se identificar a direção provável do movimento, classificando o comportamento esperado em categorias como alta, baixa ou estabilidade.

Além disso, muitos estudos sobre predição de tendências em ações são aplicados a mercados internacionais, como Estados Unidos, China, Índia e outros mercados asiáticos. Há estudos com dados dos Estados Unidos, como os trabalhos de [You et al. \(2024\)](#) e [Hu e Shen \(2026\)](#); estudos com dados do mercado chinês, como [Tian et al. \(2024\)](#) e [Chen et al. \(2025\)](#); e estudos com dados do mercado indiano, como [Sinha et al. \(2022\)](#) e [Manjunath, Marimuthu e Ghosh \(2021\)](#). Embora esses trabalhos apresentem contribuições importantes e exista ao menos um estudo diretamente relacionado ao mercado brasileiro, como o de [Padovani e Junior \(2021\)](#), ainda há espaço para novas investigações voltadas a ativos negociados na B3 e às características próprias desse ambiente financeiro.

Outro fator que motiva este trabalho é a possibilidade de aplicar redes neurais LSTM a dados históricos do mercado brasileiro. Como as LSTMs são projetadas para lidar com dados sequenciais, elas representam uma alternativa adequada para investigar séries temporais financeiras. Dessa forma, este trabalho busca verificar como essa arquitetura pode ser utilizada na classificação de tendências em ações brasileiras.

1.2 Objetivos

Esta seção apresenta o objetivo geral e os objetivos específicos deste trabalho.

1.2.1 Objetivo geral

O objetivo geral deste trabalho é desenvolver um modelo baseado em rede neural LSTM para a predição de tendências em ações do mercado brasileiro, classificando movimentos futuros em alta, baixa ou estabilidade a partir de dados históricos financeiros.

1.2.2 Objetivos específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- coletar dados históricos de ativos negociados na B3;
- realizar o pré-processamento dos dados financeiros, tratando inconsistências e normalizando os atributos de entrada;
- construir janelas temporais deslizantes a partir das séries históricas dos ativos selecionados;
- definir os rótulos das tendências futuras em alta, baixa e estabilidade com base na variação percentual do preço de fechamento;
- implementar uma arquitetura de rede neural LSTM para classificação multiclasse de tendências;
- treinar e validar o modelo utilizando uma divisão cronológica dos dados;
- avaliar o desempenho do modelo por meio de métricas de classificação.

1.3 Justificativa

Este trabalho se justifica pela relevância da predição de tendências no mercado financeiro e pela necessidade de estudos voltados ao contexto brasileiro. A literatura recente mostra que redes neurais e técnicas de aprendizado profundo têm sido utilizadas em diferentes tarefas de predição no mercado de ações, incluindo previsão de preço, classificação de movimento, predição de direção e apoio à decisão de compra e venda.

A escolha pela predição de tendências, em vez da previsão exata de preços, permite formular o problema como uma tarefa de classificação. Essa abordagem é adequada porque reduz a dependência de estimativas numéricas exatas e direciona a análise para a identificação do comportamento futuro do ativo. Assim, o modelo busca indicar uma tendência provável, o que permite uma interpretação mais direta dos resultados.

A utilização de uma rede LSTM também se justifica pela natureza sequencial dos dados financeiros. Como os preços e volumes de ações são registrados ao longo do tempo, é

importante utilizar uma arquitetura capaz de processar dependências temporais. As LSTMs são adequadas para esse tipo de problema, pois possuem mecanismos internos de memória que permitem preservar informações relevantes ao longo da sequência (HOCHREITER; SCHMIDHUBER, 1997).

Além disso, o foco no mercado brasileiro contribui para ampliar as investigações voltadas a ativos negociados na B3. A análise da literatura mostra que grande parte dos estudos sobre predição de tendências em ações utiliza dados de mercados internacionais, como Estados Unidos, China, Índia e outros mercados asiáticos. Entre os 14 trabalhos analisados, apenas o estudo de Padovani e Junior (2021) utiliza diretamente dados relacionados ao mercado brasileiro, com ações do Ibovespa e o ETF BOVA11. Portanto, não se trata de afirmar a inexistência de pesquisas sobre o Brasil, mas de reconhecer que esse recorte ainda é menos frequente na literatura analisada. Dessa forma, este trabalho busca contribuir com a análise da aplicação de redes neurais LSTM à predição de tendências em ações do mercado brasileiro.

A proposta também apresenta relevância acadêmica por integrar conceitos de mercado financeiro, séries temporais, aprendizado profundo, classificação multiclasse e avaliação experimental. Ao utilizar dados históricos, janelas temporais, rotulagem de tendências e métricas de classificação, o trabalho oferece uma metodologia estruturada para investigar o desempenho de uma arquitetura recorrente simples em um problema real de predição financeira.

O objetivo deste trabalho não é desenvolver uma estratégia de investimento ou fazer recomendações financeiras, mas analisar, de forma experimental, o uso de uma arquitetura LSTM para classificar tendências com base em dados históricos do mercado.

1.4 Estrutura do trabalho

Este trabalho está organizado em sete capítulos. O Capítulo 1 apresenta a introdução, a motivação, os objetivos, a justificativa e a estrutura do trabalho.

O Capítulo 2 apresenta a fundamentação teórica necessária para a compreensão da pesquisa. Nesse capítulo, são abordados conceitos relacionados ao mercado de ações, séries temporais financeiras, predição de tendências, aprendizado de máquina, aprendizado profundo, redes neurais artificiais, redes neurais recorrentes, LSTM, pré-processamento, classificação multiclasse e métricas de avaliação.

O Capítulo 3 apresenta os trabalhos relacionados à predição de tendências em ações com redes neurais e técnicas de aprendizado profundo. Nesse capítulo, são descritos o método de seleção dos artigos, a análise dos estudos selecionados e as principais lacunas identificadas na literatura.

O Capítulo 4 descreve a metodologia proposta para este trabalho. São apresentadas as etapas de seleção dos ativos, coleta dos dados, pré-processamento, construção das entradas, rotulagem das tendências, divisão dos dados, definição do modelo LSTM, treinamento, predição e avaliação dos resultados.

O Capítulo 5 apresenta os resultados esperados com o desenvolvimento deste trabalho, incluindo a organização dos dados, a rotulagem das tendências, o desempenho esperado do modelo LSTM, a viabilidade da abordagem e as limitações previstas.

O Capítulo 6 apresenta o cronograma de desenvolvimento do trabalho, com a distribuição das principais atividades ao longo do segundo semestre de 2026.

O Capítulo 7 apresenta as considerações finais, retomando a proposta do trabalho, suas contribuições esperadas, suas limitações e possíveis direções futuras.

Por fim, são apresentadas as referências utilizadas no desenvolvimento deste trabalho.

2 Fundamentação Teórica

Este capítulo apresenta os principais conceitos teóricos necessários para a compreensão deste trabalho. Inicialmente, são abordados conceitos relacionados ao mercado de ações e às séries temporais financeiras. Em seguida, discute-se a predição de tendências em ações, destacando a diferença entre prever preços futuros e classificar movimentos de mercado. Posteriormente, são apresentados conceitos de aprendizado de máquina, redes neurais artificiais e redes neurais recorrentes. Por fim, são descritos aspectos relacionados ao pré-processamento dos dados, à classificação multiclasse de tendências e às principais métricas utilizadas na avaliação de modelos de classificação.

2.1 Mercado de ações e séries temporais financeiras

O mercado de ações é um ambiente no qual investidores negociam participações em empresas de capital aberto. As ações correspondem a valores mobiliários emitidos por sociedades anônimas e representam uma parcela do capital social da empresa emissora. Assim, ao adquirir uma ação, o investidor passa a deter participação na sociedade da empresa (B3, 2026a). No Brasil, a negociação de ações ocorre principalmente por meio da B3¹, bolsa de valores brasileira responsável pela infraestrutura de negociação de diversos ativos financeiros, incluindo ações, fundos imobiliários, derivativos e fundos de índice (B3, 2026d).

Além das ações, também existem os ETFs, do inglês *Exchange Traded Funds*, que são fundos negociados em bolsa e que buscam acompanhar o desempenho de determinado índice ou conjunto de ativos. Um exemplo relacionado ao mercado brasileiro é o BOVA11, ETF que busca refletir o desempenho do índice Ibovespa. Por esse motivo, ações, índices e ETFs representam instrumentos relevantes para estudos que analisam o comportamento do mercado brasileiro de renda variável (B3, 2026b). O Ibovespa, por sua vez, é o principal indicador de desempenho das ações negociadas na B3 e reúne ativos com maior representatividade no mercado acionário brasileiro² (B3, 2026c).

Os dados gerados pelas negociações de ativos financeiros podem ser organizados na forma de séries temporais financeiras. Uma série temporal é uma sequência de observações ordenadas no tempo. No contexto do mercado de ações, essas observações podem representar os preços e volumes negociados de um ativo em intervalos regulares, como dias, semanas,

¹ Disponível em: <https://www.b3.com.br/pt_br/>. Acesso em: 5 jun. 2026.

² A composição atual da carteira do Ibovespa pode ser consultada no site da B3, em: <<https://sistemaswebb3-listados.b3.com.br/indexPage/day/IBOV?language=pt-br>>. Acesso em: 12 jun. 2026.

meses ou períodos intradiários. Segundo Tsay (2010), séries temporais financeiras são utilizadas para analisar o comportamento de ativos ao longo do tempo, permitindo estudar padrões, dependências temporais, volatilidade e riscos associados ao mercado.

Entre os dados mais utilizados em análises financeiras estão os dados OHLCV, sigla em inglês para *Open, High, Low, Close and Volume*. O preço de abertura, ou *Open*, corresponde ao primeiro valor negociado em determinado período. O preço máximo, ou *High*, representa o maior valor atingido pelo ativo nesse intervalo. O preço mínimo, ou *Low*, indica o menor valor observado no período. O preço de fechamento, ou *Close*, corresponde ao último valor negociado no intervalo analisado. O volume, ou *Volume*, representa a quantidade de ativos negociados durante o período. Na literatura de finanças, dados de preço e volume são frequentemente utilizados para a análise de séries temporais financeiras (TSAY, 2010).

A Figura 1 apresenta uma representação simplificada dos dados OHLCV por meio de dois gráficos. No painel superior, os preços OHLC são representados por candles, enquanto, no painel inferior, é apresentado o volume negociado. Na ilustração, os corpos brancos indicam períodos de alta, enquanto os corpos em cinza indicam períodos de baixa.




Figura 1 – Representação simplificada dos dados OHLCV: (a) preços OHLC em gráfico de candles e (b) volume negociado.

Fonte: Elaborado pelo autor (2026).

Esses dados são relevantes porque sintetizam o comportamento de negociação de um ativo ao longo do tempo. O preço de fechamento é frequentemente utilizado como referência em estudos de séries temporais financeiras, pois representa o valor final de negociação em determinado intervalo. O volume negociado também pode indicar a intensidade da participação dos investidores em determinado movimento de mercado (TSAY, 2010).

As séries temporais financeiras apresentam características que dificultam sua modelagem. Entre elas, destacam-se a volatilidade, a presença de ruídos, a não estacionariedade

e a influência de fatores externos. A volatilidade está relacionada à intensidade das variações de preço ao longo do tempo. O ruído representa oscilações que podem não carregar informação útil para a previsão. A não estacionariedade ocorre quando propriedades estatísticas da série, como média e variância, mudam ao longo do tempo. Essas características tornam a predição no mercado financeiro uma tarefa complexa, pois padrões observados em determinado período podem não se repetir da mesma forma em períodos futuros (TSAY, 2010).

Apesar dessas dificuldades, séries temporais financeiras são amplamente utilizadas em modelos computacionais de predição. A partir de dados históricos de preço e volume, é possível construir representações temporais que servem como entrada para algoritmos de aprendizado de máquina. Conforme exposto por Bishop (2006), modelos de aprendizado de máquina ajustam seus parâmetros a partir de exemplos observados, buscando reconhecer padrões nos dados. No contexto financeiro, essa lógica permite utilizar dados históricos como base para estimar comportamentos futuros dos ativos.

2.1.1 Predição de tendência em ações

A predição no mercado financeiro pode ser formulada de diferentes maneiras. Uma abordagem comum consiste na previsão direta de preços, em que o objetivo é estimar o valor futuro de um ativo. Nesse caso, o modelo busca prever, por exemplo, qual será o preço de fechamento de uma ação no próximo dia de negociação ou em outro horizonte temporal definido. Essa formulação está associada à análise e previsão de séries temporais financeiras (TSAY, 2010).

Outra abordagem consiste na predição de tendências, em que o objetivo não é estimar exatamente o preço futuro, mas identificar a direção provável do movimento do ativo. Nesse tipo de formulação, busca-se classificar se o preço tende a subir, cair ou permanecer relativamente estável. Essa abordagem transforma o problema de previsão em uma tarefa de classificação, na qual a saída do modelo corresponde a uma classe de movimento futuro, e não a um valor numérico exato.

A previsão exata de preços pode ser uma tarefa difícil devido à natureza ruidosa, volátil e não estacionária das séries financeiras. Pequenas mudanças em fatores econômicos, políticos ou comportamentais podem alterar rapidamente o preço de um ativo. Por esse motivo, a predição de tendências pode ser uma alternativa mais adequada quando o objetivo é identificar a direção geral do movimento do mercado, especialmente em aplicações de apoio à decisão.

Na predição de tendências, os movimentos futuros podem ser representados por classes. Em uma formulação binária, as classes podem indicar apenas alta ou baixa. Em uma formulação multiclasse, pode-se incluir também a classe de estabilidade, representando

situações em que a variação do preço não é suficientemente relevante para caracterizar uma tendência clara de alta ou baixa. Em estudos de predição de tendência de preços, essa formulação ternária aparece como uma estratégia para diferenciar movimentos ascendentes, descendentes e estáveis (PRATA et al., 2024).

A classificação em alta, baixa e estabilidade permite transformar variações futuras de preço em rótulos interpretáveis. A classe alta indica uma variação positiva relevante do ativo em determinado horizonte futuro. A classe baixa indica uma variação negativa relevante. A classe estabilidade representa variações pequenas, consideradas insuficientes para caracterizar um movimento direcional significativo.

Essa formulação se aproxima de aplicações práticas de apoio à decisão. Em vez de informar um preço futuro exato, o modelo fornece uma indicação da tendência esperada, que pode ser interpretada como um possível sinal de compra, venda ou manutenção. Dessa forma, a predição de tendências não elimina a incerteza do mercado financeiro, mas organiza o problema de forma mais compatível com tarefas de classificação e avaliação por métricas apropriadas.

2.2 Aprendizado de máquina

O aprendizado de máquina é uma área da inteligência artificial voltada ao desenvolvimento de algoritmos capazes de aprender padrões a partir de dados. Em vez de serem programados explicitamente com regras fixas, esses algoritmos ajustam seus parâmetros com base em exemplos observados, buscando melhorar seu desempenho em uma tarefa específica. Segundo Bishop (2006), essa abordagem permite construir modelos capazes de reconhecer padrões e generalizar decisões a partir de dados previamente observados.

Em problemas supervisionados, o modelo aprende a partir de um conjunto de dados composto por entradas e saídas conhecidas. As entradas representam as informações fornecidas ao algoritmo, enquanto as saídas representam os valores ou classes esperadas. Após o treinamento, espera-se que o modelo seja capaz de generalizar o conhecimento aprendido para novos dados, não utilizados diretamente durante o ajuste dos parâmetros (BISHOP, 2006).

O aprendizado supervisionado pode ser aplicado a problemas de regressão e classificação. Na regressão, o objetivo é prever um valor numérico contínuo, como o preço futuro de um ativo. Na classificação, o objetivo é atribuir uma amostra a uma categoria previamente definida, como alta, baixa ou estabilidade. No contexto da predição de tendências em ações, a classificação é uma formulação adequada quando se busca identificar a direção provável do movimento futuro do ativo.

O aprendizado profundo, ou *deep learning*, é uma subárea do aprendizado de

máquina baseada em redes neurais artificiais com múltiplas camadas. De acordo com [Goodfellow, Bengio e Courville \(2016\)](#), modelos de aprendizado profundo são capazes de aprender representações em diferentes níveis de abstração, o que os torna úteis em tarefas que envolvem relações não lineares e grande quantidade de informações.

Entre as arquiteturas utilizadas em aprendizado profundo estão redes neurais densas, redes convolucionais, redes recorrentes e arquiteturas baseadas em atenção ([GOODFELLOW; BENGIO; COURVILLE, 2016](#); [VASWANI et al., 2017](#)). As redes recorrentes são especialmente relevantes para dados sequenciais, pois processam informações considerando a ordem temporal das observações. As redes LSTM, propostas por [Hochreiter e Schmidhuber \(1997\)](#), foram desenvolvidas para lidar com dependências temporais de longo prazo em sequências. Arquiteturas baseadas em atenção, como os Transformers, foram posteriormente propostas por [Vaswani et al. \(2017\)](#) e passaram a ser utilizadas em diferentes problemas de modelagem sequencial.

Neste trabalho, o foco está em uma arquitetura LSTM aplicada à classificação de tendências. A escolha se justifica pela relação direta entre LSTM e dados sequenciais, além de sua adequação ao objetivo de analisar janelas temporais de dados históricos. Modelos mais recentes, como arquiteturas baseadas em atenção, Transformers e redes neurais em grafos, são importantes para contextualizar o avanço da área, mas apresentam maior complexidade computacional e metodológica.

2.2.1 Redes neurais artificiais

As redes neurais artificiais são modelos computacionais inspirados, de forma abstrata, no funcionamento de sistemas neurais biológicos. Elas são compostas por unidades chamadas neurônios artificiais, organizadas em camadas. Cada neurônio recebe entradas, aplica pesos a essas entradas, soma os resultados e utiliza uma função de ativação para produzir uma saída. Segundo [Goodfellow, Bengio e Courville \(2016\)](#), redes neurais podem aprender representações complexas dos dados por meio do ajuste de seus parâmetros durante o treinamento.

Uma rede neural típica possui uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. A camada de entrada recebe os dados fornecidos ao modelo. As camadas ocultas realizam transformações intermediárias, buscando extrair padrões e relações relevantes. A camada de saída produz o resultado final da rede, que pode ser um valor contínuo em problemas de regressão ou uma distribuição de probabilidades em problemas de classificação.

Durante o treinamento, a rede compara sua saída com o valor esperado e calcula um erro por meio de uma função de perda. Em seguida, os pesos da rede são ajustados com o objetivo de reduzir esse erro ao longo das épocas de treinamento. Esse processo

permite que a rede aprenda gradualmente relações entre os dados de entrada e as saídas esperadas ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)).

As funções de ativação exercem papel importante nesse processo, pois introduzem não linearidade ao modelo. Sem funções de ativação não lineares, a rede neural teria capacidade limitada de representar relações complexas. Em problemas de classificação multiclasse, a função Softmax é frequentemente utilizada na camada de saída, pois transforma os valores produzidos pela rede em probabilidades associadas a cada classe ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)).

Em séries temporais, redes neurais densas tradicionais podem não ser suficientes para capturar a ordem temporal dos dados, pois tratam as entradas de maneira menos dependente da sequência. Por esse motivo, arquiteturas específicas para dados sequenciais, como redes neurais recorrentes e LSTM, tornam-se mais adequadas para problemas nos quais a ordem das observações carrega informação relevante.

2.2.1.1 Redes neurais recorrentes

As redes neurais recorrentes, ou RNNs, foram desenvolvidas para processar dados sequenciais. Diferentemente de redes densas tradicionais, uma RNN utiliza conexões recorrentes que permitem manter informações de etapas anteriores da sequência. Assim, o modelo consegue considerar o contexto temporal ao processar uma nova observação ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)).

Em séries temporais financeiras, essa característica é relevante porque os preços e volumes de um ativo são observados ao longo do tempo. A informação de períodos anteriores pode contribuir para a análise do comportamento futuro do ativo. No entanto, RNNs tradicionais podem enfrentar dificuldades para aprender dependências longas, especialmente devido ao problema do desaparecimento ou explosão do gradiente durante o treinamento.

2.2.1.1.1 Redes LSTM

A arquitetura LSTM, proposta por [Hochreiter e Schmidhuber \(1997\)](#), foi desenvolvida para superar limitações das RNNs tradicionais no aprendizado de dependências de longo prazo. A LSTM introduz uma estrutura de memória controlada por portas, permitindo que a rede mantenha, atualize ou descarte informações ao longo da sequência.

De forma geral, uma célula LSTM possui mecanismos conhecidos como porta de esquecimento, porta de entrada e porta de saída. A porta de esquecimento controla quais informações anteriores devem ser descartadas. A porta de entrada define quais novas informações serão armazenadas. A porta de saída determina quais informações da memória serão utilizadas para produzir a saída da célula. Essa estrutura permite que a LSTM

preserve informações relevantes por períodos maiores, reduzindo limitações comuns das RNNs tradicionais (GOODFELLOW; BENGIO; COURVILLE, 2016).

A Figura 2 apresenta uma representação simplificada de uma célula LSTM, destacando a entrada atual, os estados anteriores, as portas internas e as saídas produzidas ao longo da sequência.




Figura 2 – Representação simplificada de uma célula LSTM.

Fonte: Elaborado pelo autor (2026).

Na Figura 2, a célula LSTM recebe como entrada os dados do instante atual, representados por x_t , juntamente com o estado oculto anterior, representado por h_{t-1} , e o estado de memória anterior, representado por C_{t-1} . A partir dessas informações, a porta de esquecimento, indicada por f_t , define quais partes da memória anterior devem ser mantidas ou descartadas. Em seguida, a porta de entrada, representada por i_t , controla quais novas informações serão incorporadas à memória da célula, em conjunto com o estado candidato $\tilde{C}_t$. A combinação entre a memória filtrada e as novas informações gera o novo estado de memória C_t .

Antes da geração da saída, esse estado de memória passa pela função de ativação tangente hiperbólica, representada por $\tanh$, que transforma os valores da memória para uma faixa limitada e contribui para controlar a informação transmitida. Por fim, a porta de saída, representada por o_t , determina quais informações do estado de memória atualizado serão utilizadas para produzir o novo estado oculto h_t , que pode ser encaminhado para a próxima etapa da sequência ou para camadas posteriores da rede (HOCHREITER; SCHMIDHUBER, 1997).

A LSTM é uma alternativa adequada e amplamente utilizada para séries temporais financeiras, pois essas séries possuem dependências temporais e comportamento sequencial. Ao receber uma janela temporal com dados históricos de um ativo, a LSTM pode aprender padrões associados a movimentos futuros. Por exemplo, a rede pode identificar combinações

de variações de preço, volume e retorno que estejam relacionadas a tendências de alta, baixa ou estabilidade.

A escolha por uma LSTM também se justifica pela sua viabilidade em comparação com arquiteturas mais complexas. Modelos como Transformers, redes neurais em grafos ou abordagens híbridas podem apresentar bons resultados em determinados contextos, mas exigem maior complexidade de implementação, maior volume de dados e maior custo computacional. Uma arquitetura LSTM simples permite manter o experimento mais controlado, facilitando a análise dos resultados e a interpretação do comportamento do modelo.

Além da camada LSTM, modelos de classificação baseados em redes neurais podem utilizar camadas auxiliares, como Dropout, camadas densas e Softmax. O Dropout é uma técnica de regularização que desativa aleatoriamente parte dos neurônios durante o treinamento, reduzindo o risco de sobreajuste ([SRIVASTAVA et al., 2014](#)). A camada densa combina as representações aprendidas pela rede. A função Softmax, por sua vez, é utilizada na saída para gerar probabilidades associadas a cada classe em problemas de classificação multiclasse ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)).

2.2.2 Pré-processamento, normalização e janelas temporais

O pré-processamento dos dados é uma etapa importante em problemas de aprendizado de máquina e aprendizado profundo, pois prepara as variáveis de entrada antes do treinamento do modelo. No contexto de séries temporais financeiras, essa etapa envolve a organização cronológica dos registros, a verificação de valores ausentes, o tratamento de inconsistências e a adequação dos atributos numéricos para uso em algoritmos de aprendizagem. Como séries financeiras são compostas por observações ordenadas no tempo, a preservação da ordem cronológica é essencial para evitar que informações futuras sejam utilizadas indevidamente durante o treinamento ([TSAY, 2010](#)).

A normalização dos dados é utilizada para reduzir diferenças de escala entre os atributos. Em dados financeiros, variáveis como preços e volume negociado podem possuir magnitudes bastante distintas. Caso esses atributos sejam fornecidos diretamente ao modelo, variáveis com valores numéricos maiores podem influenciar de forma desproporcional o processo de aprendizagem. Conforme discutido por [Bishop \(2006\)](#), a preparação adequada das variáveis de entrada contribui para melhorar o treinamento e a capacidade de generalização dos modelos.

Em redes neurais, a escala dos dados também influencia o processo de otimização. Modelos de aprendizado profundo ajustam seus parâmetros por meio de algoritmos baseados em gradiente, e entradas com escalas muito diferentes podem dificultar a convergência do treinamento. Dessa forma, a normalização contribui para tornar o processo de aprendizagem

mais estável, especialmente quando são utilizados atributos financeiros com unidades e amplitudes distintas ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)).

Além da normalização, séries temporais precisam ser organizadas em uma estrutura compatível com modelos sequenciais. Uma estratégia comum consiste no uso de janelas temporais deslizantes, nas quais um conjunto de observações passadas é utilizado como entrada para prever ou classificar um comportamento futuro. Assim, em vez de analisar cada registro de forma isolada, o modelo recebe uma sequência ordenada de dados históricos.

No contexto deste trabalho, uma janela temporal representa um conjunto de dias anteriores de negociação de um ativo. Essa sequência será utilizada como entrada da rede neural, enquanto a saída estará associada à tendência futura observada em um horizonte definido. Essa organização é adequada para modelos recorrentes, como a LSTM, pois permite que a rede processe informações temporais e explore padrões presentes na sequência histórica dos dados.

Também é necessário definir uma estratégia adequada de divisão dos dados. Em séries temporais financeiras, a separação entre treinamento, validação e teste deve respeitar a ordem cronológica das observações. Diferentemente de bases de dados independentes, o embaralhamento aleatório dos registros pode introduzir vazamento de informação futura, prejudicando a validade da avaliação. Por isso, os dados mais antigos devem ser utilizados no treinamento, enquanto os períodos posteriores devem ser reservados para validação e teste, simulando uma situação mais próxima do uso real do modelo.

2.2.3 Classificação multiclasse de tendências

A classificação multiclasse ocorre quando um modelo precisa escolher uma entre três ou mais classes possíveis. De acordo com [Bishop \(2006\)](#), problemas de classificação consistem em atribuir uma entrada a uma categoria previamente definida. No contexto da predição de tendências em ações, essa formulação permite representar diferentes comportamentos futuros do preço de um ativo.

Para transformar uma série de preços em um problema de classificação, é necessário definir rótulos para as amostras. Esses rótulos são construídos a partir da variação futura do preço em determinado horizonte temporal. Assim, cada janela de dados históricos recebe uma classe associada ao comportamento observado no futuro.

Uma forma comum de realizar essa rotulagem consiste em calcular a variação percentual entre o preço atual e o preço futuro. Quando essa variação é positiva e supera determinado limite, a amostra pode ser rotulada como alta. Quando a variação é negativa e fica abaixo de determinado limite negativo, a amostra pode ser rotulada como baixa. Quando a variação permanece dentro de uma faixa intermediária, a amostra pode ser rotulada como estabilidade. Estratégias de rotulagem baseadas em horizontes futuros e

classes de alta, baixa e estabilidade são utilizadas em estudos de predição de tendência de preços (PRATA et al., 2024).

Nesse processo, variações positivas relevantes são associadas à classe alta, variações negativas relevantes são associadas à classe baixa e variações pequenas, dentro dos limites definidos, são associadas à classe estabilidade.

A definição dos limiares é uma etapa importante, pois influencia diretamente a distribuição das classes. Limiares muito pequenos podem tornar os rótulos sensíveis a pequenas oscilações de preço, fazendo com que ruídos do mercado sejam tratados como tendências relevantes. Por outro lado, limiares muito altos podem concentrar muitas amostras na classe de estabilidade, dificultando o aprendizado das demais classes. Portanto, a escolha dos limiares deve considerar o comportamento da série analisada, a volatilidade dos ativos e a distribuição dos rótulos gerados.

A classificação multiclasse permite que a saída do modelo seja interpretada de forma mais direta. Em uma rede neural com função Softmax na camada final, a saída é uma distribuição de probabilidades entre as classes (GOODFELLOW; BENGIO; COURVILLE, 2016). Por exemplo, o modelo pode atribuir 70% de probabilidade para alta, 20% para estabilidade e 10% para baixa. Nesse caso, a classe com maior probabilidade é escolhida como previsão final.

Esse tipo de formulação é adequado para problemas de apoio à decisão, pois a saída do modelo não depende de um preço exato, mas de uma indicação categórica da tendência esperada. Ainda assim, a classificação de tendências continua sujeita às incertezas do mercado financeiro e deve ser avaliada com métricas apropriadas.

2.2.4 Métricas de avaliação para classificação

A avaliação de modelos de classificação é realizada por meio da comparação entre as classes previstas pelo modelo e as classes reais observadas. Em problemas de classificação de tendências, essa avaliação permite verificar se o modelo consegue identificar corretamente movimentos de alta, baixa e estabilidade. Conforme Sokolova e Lapalme (2009), medidas como acurácia, precisão, recall e F1-score são amplamente utilizadas para avaliar classificadores.

A acurácia é uma das métricas mais simples e indica a proporção total de previsões corretas em relação ao número total de amostras avaliadas. Embora seja intuitiva, a acurácia pode ser limitada quando as classes estão desbalanceadas. Se a maior parte das amostras pertence a uma única classe, um modelo pode apresentar acurácia elevada apenas por prever frequentemente a classe majoritária (SOKOLOVA; LAPALME, 2009).

A precisão indica, entre as amostras classificadas pelo modelo como pertencentes a uma determinada classe, quantas realmente pertencem a essa classe. Em outras palavras,

ela avalia a confiabilidade das previsões feitas para uma classe específica. No contexto financeiro, a precisão pode indicar, por exemplo, quantas previsões de alta realmente corresponderam a movimentos de alta.

O recall mede a capacidade do modelo de identificar corretamente os exemplos reais de determinada classe. Ele mostra quantas amostras de uma classe foram corretamente reconhecidas pelo modelo. Essa métrica é importante quando se deseja avaliar se o modelo consegue capturar adequadamente os casos reais de cada tendência.

O F1-score combina precisão e recall em uma única medida, utilizando a média harmônica entre essas duas métricas. Ele é especialmente útil quando há desequilíbrio entre as classes, pois permite avaliar o equilíbrio entre a confiabilidade das previsões e a capacidade de identificar corretamente os exemplos reais (SOKOLOVA; LAPALME, 2009).

A matriz de confusão apresenta uma visão detalhada dos acertos e erros do modelo. Ela organiza as classes reais e as classes previstas em uma tabela, permitindo observar quais classes foram corretamente classificadas e quais foram confundidas entre si. Em um problema com as classes alta, baixa e estabilidade, a matriz de confusão permite identificar, por exemplo, se o modelo confunde frequentemente estabilidade com alta ou baixa com alta.

A utilização conjunta dessas métricas fornece uma avaliação mais completa do desempenho do modelo. Enquanto a acurácia oferece uma visão geral dos acertos, precisão, recall e F1-score permitem analisar o desempenho por classe. A matriz de confusão, por sua vez, ajuda a compreender os tipos de erro cometidos pelo modelo e a interpretar melhor suas limitações.

2.3 Considerações finais do capítulo

Este capítulo apresentou os conceitos fundamentais necessários para a compreensão da proposta deste trabalho. Inicialmente, foram abordados o mercado de ações, a B3, ações, ETFs e séries temporais financeiras, com destaque para os dados OHLCV. Em seguida, foi discutida a diferença entre previsão de preços e predição de tendências, destacando a formulação do problema como uma tarefa de classificação.

Também foram apresentados conceitos de aprendizado de máquina, aprendizado profundo e redes neurais artificiais, com ênfase nas redes neurais recorrentes e na arquitetura LSTM. A LSTM foi discutida como uma alternativa adequada para o processamento de sequências temporais, devido à sua capacidade de preservar informações relevantes ao longo do tempo.

Por fim, foram descritos os conceitos de classificação multiclasse de tendências e

as principais métricas de avaliação para problemas de classificação, incluindo acurácia, precisão, recall, F1-score e matriz de confusão. Esses conceitos servem como base teórica para os capítulos seguintes, nos quais são analisados os trabalhos relacionados e apresentada a metodologia proposta para a predição de tendências em ações do mercado brasileiro utilizando uma rede neural LSTM.

3 Trabalhos Relacionados

Neste capítulo são apresentados e discutidos os trabalhos relacionados à predição de tendências, movimentos ou direção de preços de ações utilizando modelos computacionais de aprendizado de máquina, com ênfase em redes neurais e técnicas de aprendizado profundo. O objetivo desta seção é analisar como diferentes arquiteturas têm sido aplicadas ao problema de previsão no mercado financeiro, destacando os dados utilizados, os métodos empregados, os resultados obtidos e as principais limitações observadas nos estudos selecionados.

A análise dos trabalhos relacionados é importante para posicionar a presente pesquisa no contexto da literatura existente, permitindo compreender quais abordagens já foram exploradas, quais técnicas apresentam melhor desempenho e quais lacunas ainda permanecem, especialmente em relação à aplicação dessas arquiteturas ao mercado brasileiro de ações.

3.1 Método de Seleção

A seleção dos trabalhos relacionados foi realizada com base no protocolo da Pesquisa Bibliográfica Sistemática definido para este trabalho. A questão de pesquisa adotada foi: “Como arquiteturas de redes neurais podem ser aplicadas à predição de tendências em ações do mercado brasileiro?”. Para responder a essa questão, foram realizadas buscas em bases acadêmicas e motores de busca científicos, como Google Acadêmico e IEEE Xplore, considerando artigos publicados nos últimos cinco anos, em inglês ou português, e priorizando publicações em journals e proceedings.

Para orientar a busca, foram utilizados termos relacionados a três grupos principais: predição de tendências, mercado de ações e redes neurais. Entre as expressões utilizadas estão “trend prediction”, “trend classification”, “price movement prediction”, “stock market”, “financial time series”, “neural networks” e “deep learning”. As strings de busca foram construídas combinando esses termos, conforme definido no protocolo da pesquisa bibliográfica sistemática.

Ao todo, a etapa inicial de busca e triagem reuniu 203 artigos. Após a aplicação dos critérios de inclusão e exclusão, além da leitura de título, palavras-chave, abstract e leitura completa, foram selecionados 14 artigos considerados aderentes ao escopo da pesquisa.

Foram considerados como critérios de inclusão:

- CI1 – abordar a predição de tendências, movimento ou direção de preços em ações

no mercado financeiro;

- CI2 – empregar redes neurais ou técnicas de deep learning aplicadas ao problema de predição;
- CI3 – apresentar aplicação prática, experimento ou avaliação de desempenho com dados do mercado de ações;
- CI4 – utilizar dados históricos, técnicos ou financeiros do mercado de ações, como preço, volume, indicadores técnicos ou séries temporais financeiras.

Como critérios de exclusão, foram desconsiderados:

- CE1 – trabalhos que tratavam exclusivamente de outros ativos financeiros, como criptomoedas, forex ou commodities, sem relação com ações;
- CE2 – estudos que utilizavam apenas métodos estatísticos tradicionais ou algoritmos de aprendizado de máquina sem redes neurais;
- CE3 – estudos secundários, como surveys, revisões sistemáticas e mapeamentos;
- CE4 – trabalhos cujo foco principal fosse análise de sentimentos, redes sociais, notícias, tweets, fóruns, opinião pública ou dados textuais sem utilizar predominantemente dados históricos ou financeiros do mercado de ações;
- CE5 – trabalhos que utilizavam redes neurais apenas para análise textual, processamento de linguagem natural ou classificação de sentimentos, sem aplicação direta na predição de tendências, movimento ou direção de preços de ações.

Além disso, quanto ao tipo de publicação, foram priorizados artigos publicados em *journals* e *proceedings*, sendo desconsiderados teses, dissertações, monografias, capítulos de livro e resumos expandidos.

3.2 Análise dos Trabalhos Relacionados

Os trabalhos analisados demonstram que a predição de tendências no mercado de ações é frequentemente tratada como um problema de classificação. Em vez de prever diretamente o preço futuro de uma ação, muitos estudos buscam identificar se o ativo apresentará movimento de alta, baixa ou estabilidade em determinado horizonte de tempo. Essa abordagem é adequada ao contexto de apoio à decisão, pois permite transformar a saída do modelo em sinais práticos de compra, venda ou manutenção.

Um dos trabalhos mais próximos ao tema desta pesquisa é o de [Padovani e Junior \(2021\)](#), que propõe o algoritmo TCTA, baseado em previsão de tendência e classificação de

séries temporais. O estudo utiliza dados de ações do Ibovespa e do ETF BOVA11, sendo, portanto, diretamente relacionado ao mercado brasileiro. Os autores transformam os preços de fechamento em sequências de variação percentual e utilizam agrupamento K-means para rotular os movimentos em três classes: subida, queda e estabilidade. Em seguida, redes DNN e LSTM são empregadas para prever a tendência futura e alimentar uma estratégia de trading baseada em sinais de compra, venda ou manutenção. Esse trabalho se destaca por aplicar redes neurais em ativos da B3, aproximando-se diretamente da proposta deste trabalho.

Muhammad et al. (2024) propõem uma abordagem de deep learning explicável para predição de tendências no mercado de ações. Diferentemente de estudos que trabalham apenas com tendência de alta ou baixa, os autores consideram cinco padrões: upward, downward, double top, rounded bottom e rounded top. O modelo proposto é comparado com Random Forest, Support Vector Machine e Regressão Logística, alcançando desempenho superior em métricas como acurácia e F1-score. Além disso, o trabalho incorpora técnicas de Explainable Artificial Intelligence, como SHAP e LIME, para tornar as decisões do modelo mais interpretáveis. Esse aspecto é relevante porque modelos de deep learning, apesar do bom desempenho, muitas vezes são criticados por sua baixa explicabilidade.

Sinha et al. (2022) apresentam uma abordagem baseada em redes neurais convolucionais tridimensionais para classificação de tendências de ações. O estudo agrupa empresas de um mesmo setor e transforma indicadores técnicos em uma representação tridimensional, permitindo que o modelo analise simultaneamente o comportamento de múltiplas empresas relacionadas. A classificação é feita em três sinais: Buy, Sell e Hold. Os experimentos foram realizados com 45 empresas da National Stock Exchange, e os resultados indicaram ganhos anuais relevantes em alguns ativos, além de retorno médio positivo. Esse trabalho contribui ao mostrar que a relação entre empresas de um mesmo setor pode ser explorada para melhorar a previsão de tendências.

Outra linha de pesquisa observada nos artigos selecionados envolve o uso de grafos para representar relações entre ações. You et al. (2024) propõem o modelo Multi-Relational Graph Diffusion Neural Network with Parallel Retention, voltado à classificação de tendências no próximo dia de negociação. O modelo constrói grafos dinâmicos entre ações a partir de medidas de entropia da informação e energia do sinal, buscando capturar tanto a direção quanto a intensidade das relações entre ativos. Os experimentos foram realizados em mercados dos Estados Unidos e da China, incluindo NASDAQ, NYSE e Shanghai Stock Exchange, e demonstraram desempenho superior a baselines do estado da arte. Esse estudo evidencia uma tendência recente da literatura: considerar que ações não se comportam de forma isolada, mas sim dentro de uma rede de relações financeiras.

De forma semelhante, Tian et al. (2024) propõem o MST-GNN, uma rede neural em grafos espacial-temporal multicamada para previsão de ações. O modelo considera

diferentes tipos de relações entre empresas e busca capturar a evolução temporal dessas conexões. Diferentemente de métodos baseados em grafos estáticos, a proposta utiliza redes espaciais-temporais multicamadas para representar relações financeiras multifacetadas e dinâmicas. Os experimentos no mercado chinês demonstraram que o modelo supera outras abordagens baseadas em GNN em tarefas de classificação de tendência e ranqueamento de retornos. Esse trabalho reforça a importância de modelar tanto a dimensão temporal quanto as dependências entre ativos.

Prata et al. (2024) realizam um estudo de benchmark com modelos de deep learning aplicados à predição de tendência de preços com dados de livro de ofertas. O trabalho analisa 15 modelos do estado da arte e propõe o framework LOBCAST, que inclui pré-processamento, treinamento, avaliação e análise de lucro. Embora os modelos apresentem bons resultados em determinados conjuntos de dados, os autores observam queda significativa de desempenho quando testados em novos cenários de mercado, indicando problemas de robustez e generalização. Essa limitação é importante para este trabalho, pois mostra que bons resultados em um dataset específico não garantem desempenho confiável em outros mercados ou períodos.

Latif et al. (2024) propõem o modelo PLSTM-TAL, que combina Peephole LSTM com uma camada de atenção temporal para prever a direção de mercados acionários. O estudo utiliza dados diários de quatro índices mundiais, incluindo mercados dos Estados Unidos, Reino Unido, China e Índia, e compara o modelo proposto com CNN, LSTM, SVM e Random Forest. Os resultados indicam que a camada de atenção temporal ajuda o modelo a identificar padrões relevantes ao longo do tempo, melhorando o desempenho em métricas como acurácia, precisão, recall e F1-score. O trabalho mostra a relevância de combinar redes recorrentes com mecanismos de atenção em séries temporais financeiras.

Xu et al. (2025) apresentam o HRformer, um Transformer relacional híbrido para previsão de séries temporais de ações. A proposta decompõe a série temporal em componentes de tendência, ciclo e volatilidade, modelando cada uma separadamente antes de integrá-las por um mecanismo adaptativo. Além disso, o modelo utiliza atenção para capturar correlações entre ações. Os experimentos foram realizados nos conjuntos NASDAQ100 e CSI300, com resultados superiores a métodos comparativos em métricas como acurácia, F1-score e Sharpe Ratio. Esse estudo mostra a evolução recente dos Transformers aplicados à predição financeira, principalmente pela capacidade de capturar dependências temporais longas e relações entre ativos.

Chen et al. (2025) propõem o MSTAN, uma rede de atenção temporal multi-escala para previsão de ações. O modelo busca lidar com três desafios recorrentes em séries financeiras: não estacionariedade, dependências temporais em múltiplas escalas e correlações entre ativos. Para isso, utiliza reconstrução periódica bidimensional, atenção temporal híbrida e um módulo adaptativo para dependências entre ações. Os resultados

em bases do mercado chinês e dos Estados Unidos indicaram redução de erro e melhor desempenho em backtesting de portfólio. Esse trabalho contribui ao destacar que diferentes horizontes temporais podem conter padrões distintos e complementares para a predição.

Hu e Shen (2026) propõem uma abordagem de análise preditiva para prever retornos relativos de índices globais utilizando LSTM, Dual-Layer LSTM e Transformer com Multi-Head Self-Attention. O estudo considera índices como S&P 500, FTSE 100, Nikkei 225, DAX 30 e CAC 40, utilizando indicadores técnicos e fundamentalistas. Os resultados indicam que o modelo Dual-Layer LSTM apresentou melhor desempenho em vários cenários, especialmente no S&P 500, alcançando bons resultados em acurácia, precisão, recall e F1-score. Esse trabalho é relevante por combinar diferentes tipos de indicadores e comparar arquiteturas recorrentes e baseadas em atenção.

Huang, Cui e Lu (2025) propõem uma estratégia de trading baseada em aprendizado por reforço profundo multi-escala e predição de movimento de preços. O método integra aprendizado supervisionado e aprendizado por reforço. Inicialmente, uma rede CNN-LSTM é utilizada para prever movimentos de preço em três classes: subida, estabilidade ou queda. Em seguida, essas previsões são incorporadas ao estado de um agente de aprendizado por reforço, que aprende estratégias de negociação por meio de Double Deep Q-Network. Os resultados em seis ativos financeiros dos Estados Unidos indicaram retorno anualizado médio superior ao de outros algoritmos de reforço profundo. Esse estudo mostra que a predição de tendência pode ser usada não apenas como resultado final, mas também como entrada para sistemas automatizados de tomada de decisão.

Ghosh e Chaudhuri (2021) propõem os modelos FEB-stacking e FEB-DNN para predição de tendência de ações, considerando períodos antes e depois da pandemia de Covid-19. O estudo utiliza ações indianas, indicadores técnicos e variáveis macroeconômicas, além de técnicas como Kernel Principal Component Analysis, bootstrapping, gradient boosting, random forest, bagging e deep neural networks. A classificação é binária, buscando prever se o preço de fechamento aumentará ou diminuirá no dia seguinte. Esse trabalho é relevante porque considera mudanças de regime de mercado, especialmente em períodos de crise, e destaca a importância de avaliar modelos em cenários normais e anormais.

Zu et al. (2026) propõem o Adv-SHNets, uma estrutura baseada em LSTM hierárquica para predição de movimento de ações. O modelo utiliza segmentação temporal sobreposta para preservar a continuidade dos dados, atenção segmentada para fusão de características e uma camada LSTM superior para capturar dependências hierárquicas. Além disso, incorpora uma função de perda adversarial para aumentar a robustez diante da incerteza dos dados financeiros. Os experimentos em datasets reais indicaram melhoria relativa em relação a métodos do estado da arte. Esse estudo contribui ao mostrar que a estrutura temporal das ações pode ser modelada em diferentes níveis hierárquicos.

Manjunath, Marimuthu e Ghosh (2021) analisam métodos de deep learning para

previsão do movimento do índice NIFTY 50, utilizando análise técnica aprimorada. O estudo avalia RNN, LSTM e três variantes de GRU com diferentes conjuntos de indicadores técnicos. Os resultados indicam que uma das variantes de GRU, combinada ao conjunto de indicadores TA1, obteve os menores valores de erro, superando os demais modelos comparados. Esse trabalho reforça a importância da escolha adequada de indicadores técnicos e mostra que arquiteturas recorrentes, especialmente GRU, podem apresentar bom desempenho em séries financeiras.

Para complementar a análise dos artigos selecionados, foi elaborada uma tabela relacional, apresentada em partes menores de acordo com as dimensões de comparação utilizadas na revisão. Essa divisão facilita a leitura dos resultados ao longo da discussão. A marcação com “X” indica que determinada característica foi identificada no artigo analisado.

A Tabela 1 apresenta uma síntese dos objetivos e dos mercados considerados nos trabalhos relacionados.

Tabela 1 – Objetivos e mercados dos trabalhos relacionados.

		Padovani e Junior (2021)	Muhammad et al. (2024)	Sinha et al. (2022)	You et al. (2024)	Tian et al. (2024)	Prata et al. (2024)	Latif et al. (2024)	Xu et al. (2025)	Chen et al. (2025)	Hu e Shen (2026)	Huang, Cui e Lu (2025)	Manjunath, Marimuthu e Ghosh (2021)
Objetivo	Predição de preço									X			
	Predição de retorno					X					X		
	Predição/classificação de tendência	X	X	X	X	X	X	X	X		X	X	X
	Sinais de negociação (compra e venda)	X		X			X				X	X	X
	Estratégia de trading	X		X		X	X	X	X	X	X	X	X
Mercado	Mercado brasileiro	X											
	Mercado dos EUA		X		X		X	X	X	X	X	X	X
	Mercado asiático		X	X	X	X		X	X	X	X		X
	Mercados globais		X					X			X		
	Ações individuais	X		X	X	X	X		X	X	X	X	X
	Índices de mercado		X					X	X		X	X	X

Fonte: Elaborado pelo autor (2026).

A partir da Tabela 1, observa-se que a maior parte dos trabalhos está concentrada na predição ou classificação de tendência. Também se nota a presença de estudos voltados a sinais de negociação e estratégias de *trading*, indicando que parte da literatura analisada

trata o problema como uma tarefa de apoio à decisão, e não apenas como previsão exata de preços.

Em relação aos mercados analisados, nota-se a predominância de estudos voltados a mercados internacionais, especialmente Estados Unidos, China, Índia e outros mercados asiáticos. Entre os trabalhos analisados, apenas o estudo de [Padovani e Junior \(2021\)](#) utiliza diretamente dados do mercado brasileiro, considerando ações do Ibovespa e o ETF BOVA11. Assim, em vez de afirmar uma ausência total de pesquisas sobre o Brasil, observa-se que dados do mercado brasileiro aparecem com menor frequência no conjunto analisado, o que indica espaço para novas contribuições voltadas especificamente ao contexto da B3.

A Tabela 2 apresenta os principais tipos de dados empregados pelos estudos analisados.

Tabela 2 – Dados utilizados nos trabalhos relacionados.

Dados		Padovani e Junior (2021)	Muhammad et al. (2024)	Sinha et al. (2022)	You et al. (2024)	Tian et al. (2024)	Prata et al. (2024)	Latif et al. (2024)	Xu et al. (2025)	Chen et al. (2025)	Hu e Shen (2026)	Huang, Cui e Lu (2025)	Manjunath, Marimuthu e Ghosh (2021)	Ghosh e Chaudhuri (2021)	Zu et al. (2026)
	Preços históricos	X	X	X	X	X	X	X	X	X	X	X	X	X	X
	OHLC			X	X	X		X	X			X	X		X
	Volume negociado				X	X	X	X				X	X		
	Indicadores técnicos	X	X	X		X		X			X		X	X	X
	Dados complementares externos					X					X			X	
	Relações entre ativos, setores ou grafos			X	X	X	X		X	X					

Fonte: Elaborado pelo autor (2026).

Quanto aos dados utilizados, os preços históricos aparecem como o principal insumo dos modelos, estando presentes em todos os trabalhos analisados. Além disso, diversos estudos utilizam dados OHLC, volume negociado, indicadores técnicos e relações entre ativos, setores ou grafos. Essa predominância reforça a importância das séries temporais financeiras e dos indicadores derivados dos preços para a construção de modelos de predição de tendências. Também se observa que alguns trabalhos incorporam dados complementares externos, como indicadores fundamentalistas, variáveis macroeconômicas, notícias ou sentimento de mercado.

A Tabela 3 sintetiza as principais técnicas e arquiteturas utilizadas nos trabalhos

relacionados.

Tabela 3 – Técnicas empregadas nos trabalhos relacionados.

Técnica		Padovani e Junior (2021)	Muhammad et al. (2024)	Sinha et al. (2022)	You et al. (2024)	Tian et al. (2024)	Prata et al. (2024)	Latif et al. (2024)	Xu et al. (2025)	Chen et al. (2025)	Hu e Shen (2026)	Huang, Cui e Lu (2025)	Manjunath, Marimuthu e Ghosh (2021)	Ghosh e Chaudhuri (2021)	Zu et al. (2026)
	Redes densas	X	X			X	X	X	X	X		X		X	X
	Redes recorrentes	X				X	X	X	X		X	X	X		X
	Redes convolucionais			X			X			X		X			X
	Transformer						X		X		X				
	Atenção temporal					X	X	X	X	X					X
	Redes neurais em grafos				X	X									
	Aprendizado por Reforço Profundo											X			
	Ensemble/stacking			X			X							X	
	Benchmark comparativo		X		X	X	X						X	X	

Fonte: Elaborado pelo autor (2026).

No que se refere às técnicas empregadas, observa-se uma grande diversidade de arquiteturas de redes neurais. Modelos baseados em redes densas, redes recorrentes, redes convolucionais, Transformers, mecanismos de atenção, redes neurais em grafos, aprendizado por reforço profundo, ensemble, stacking e benchmarks comparativos aparecem nos estudos analisados. As arquiteturas recorrentes, especialmente LSTM, RNN e GRU, são bastante frequentes por sua capacidade de lidar com dados sequenciais. Já os modelos baseados em atenção, Transformers e grafos representam abordagens mais recentes, voltadas a capturar dependências temporais longas e relações entre diferentes ações.

A Tabela 4 apresenta os métodos comparados, as métricas de avaliação e os horizontes de predição adotados pelos estudos.

Tabela 4 – Métodos, métricas e horizontes de predição.

		Padovani e Junior (2021)	Muhammad et al. (2024)	Sinha et al. (2022)	You et al. (2024)	Tian et al. (2024)	Prata et al. (2024)	Latif et al. (2024)	Xu et al. (2025)	Chen et al. (2025)	Hu e Shen (2026)	Huang, Cui e Lu (2025)	Manjunath, Marimuthu e Ghosh (2021)	Ghosh e Chaudhuri (2021)	Zu et al. (2026)
Comparações	Estatísticos/ML tradicional		X				X	X			X			X	
	Outras redes neurais	X		X	X	X	X	X	X	X	X	X	X		X
	Estratégias financeiras de referência	X		X		X			X	X		X		X	
Métricas	Métricas de classificação		X	X	X	X	X	X	X		X	X		X	X
	Métricas de erro									X		X	X		
	Métricas financeiras	X		X		X	X		X	X	X	X		X	
Horizonte	Intradiário						X					X			X
	Diário	X	X	X	X	X		X	X	X	X	X	X	X	
	Semanal ou superior			X					X		X				X

Fonte: Elaborado pelo autor (2026).

A análise mostra que a maior parte dos trabalhos realiza comparação com outras redes neurais, métodos tradicionais de *machine learning*, métodos estatísticos ou estratégias financeiras de referência. Isso é importante porque permite avaliar se os modelos propostos realmente apresentam ganhos em relação a abordagens já consolidadas.

Em relação às métricas, destacam-se métricas de classificação, como acurácia, precisão, recall e F1-score; métricas de erro, como RMSE, MAE e MAPE; e métricas financeiras, como lucro, retorno financeiro, Sharpe ratio e taxa de acerto. Essa combinação indica que os estudos buscam avaliar tanto o desempenho preditivo quanto a utilidade financeira dos modelos. Quanto ao horizonte de predição, a frequência diária aparece com maior destaque entre os trabalhos analisados, enquanto alguns estudos também consideram horizontes intradiários ou semanais e superiores. Esse resultado se aproxima da proposta metodológica deste trabalho, que também se baseia em dados históricos organizados

temporalmente.

Por fim, a Tabela 5 apresenta a síntese dos resultados, limitações e possibilidades de aplicação prática observadas nos artigos.

Tabela 5 – Resultados, limitações e aplicabilidade.

		Padovani e Junior (2021)	Muhammad et al. (2024)	Sinha et al. (2022)	You et al. (2024)	Tian et al. (2024)	Prata et al. (2024)	Latif et al. (2024)	Xu et al. (2025)	Chen et al. (2025)	Hu e Shen (2026)	Huang, Cui e Lu (2025)	Manjunath, Marimuthu e Ghosh (2021)	Ghosh e Chaudhuri (2021)	Zu et al. (2026)
Resultado	Supera baselines	X	X	X	X	X		X	X	X	X	X	X	X	X
	Ganho financeiro	X		X		X	X		X	X	X	X		X	X
	Melhor generalização		X		X					X	X				X
Limitações	Dependência de mercado específico	X		X		X	X		X	X	X		X	X	X
	Dependência de dataset específico	X	X	X	X	X	X	X	X	X	X	X	X	X	
	Alto custo computacional				X	X	X					X			
	Poucos dados						X								
	Não considera custos de transação	X		X			X	X		X					X
Aplicabilidade	Apoio à decisão/análise de mercado	X	X	X	X	X	X	X	X	X	X	X	X	X	
	Trading automatizado	X		X		X	X		X	X	X	X			
	Recomendação de compra/venda	X		X		X	X		X	X	X	X		X	X
	Gestão de risco		X					X	X	X	X	X			X

Fonte: Elaborado pelo autor (2026).

Os resultados indicam que a maior parte dos modelos apresentou desempenho superior aos baselines, além de ganho financeiro em alguns casos e melhor generalização em determinados estudos. Entretanto, esses resultados devem ser interpretados com cautela, pois bons desempenhos em bases específicas não garantem generalização para outros mercados, períodos ou condições econômicas.

As limitações mais recorrentes envolvem dependência de mercado específico, dependência de dataset específico e ausência de custos de transação em parte dos estudos. Além disso, alguns trabalhos também apontam limitações relacionadas ao alto custo

computacional e à quantidade reduzida de dados. Essas limitações são relevantes para este trabalho, pois mostram que bons resultados em um conjunto de dados específico não garantem que o modelo terá desempenho semelhante em outros cenários.

Por fim, quanto à aplicabilidade, os trabalhos analisados apresentam forte relação com apoio à decisão, análise de mercado, trading automatizado, recomendação de compra e venda e gestão de risco. Isso demonstra que a predição de tendências com redes neurais não possui apenas interesse teórico, mas também potencial de aplicação prática em sistemas de suporte ao investidor e estratégias automatizadas.

3.3 Considerações Finais do Capítulo

A análise dos trabalhos relacionados permite observar que a predição de tendências em ações tem sido abordada, principalmente, como uma tarefa de classificação, voltada à identificação de movimentos de alta, baixa ou estabilidade. Essa forma de modelagem se mostra adequada ao objetivo deste trabalho, pois aproxima a predição de uma aplicação prática de apoio à decisão no mercado financeiro.

Os estudos analisados também evidenciam a diversidade de arquiteturas de redes neurais aplicadas ao problema, incluindo modelos recorrentes, convolucionais, mecanismos de atenção, Transformers, redes neurais em grafos e arquiteturas híbridas. Apesar dos bons resultados apresentados em diferentes mercados, observa-se que grande parte dos trabalhos ainda está concentrada em contextos internacionais, como Estados Unidos, China, Índia e outros mercados asiáticos.


Nesse sentido, observa-se espaço para novas investigações relacionadas à aplicação dessas técnicas no mercado brasileiro de ações. Entre os 14 estudos analisados, apenas o trabalho de [Padovani e Junior \(2021\)](#) utiliza diretamente dados do Ibovespa e do ETF BOVA11, o que mostra que esse recorte ainda é pouco frequente no conjunto analisado. Assim, este trabalho busca contribuir para essa discussão ao analisar como arquiteturas de redes neurais podem ser aplicadas à predição de tendências em ações do mercado brasileiro.

4 Metodologia

Este capítulo apresenta a metodologia proposta para a predição de tendências em ações do mercado brasileiro utilizando uma rede neural recorrente do tipo LSTM, cuja fundamentação teórica foi apresentada na Seção 2.2.1.1.1. A abordagem adotada segue a formulação de classificação multiclasse discutida na Seção 2.2.3, na qual a tendência futura do ativo é representada por uma das três classes: alta, baixa ou estabilidade.

O método proposto é organizado como um fluxo sequencial de processamento, iniciando pela seleção dos ativos e coleta dos dados históricos, passando pelo pré-processamento, construção das entradas, rotulagem das tendências, treinamento do modelo e avaliação dos resultados. A Figura 3 apresenta o diagrama geral da metodologia adotada.

Figura 3 – Diagrama da metodologia utilizada.



Fonte: Elaborado pelo autor (2026)

O fluxo metodológico está dividido em três etapas principais. A primeira corresponde

ao tratamento dos dados, incluindo a seleção dos ativos, a coleta das informações históricas e o pré-processamento. A segunda corresponde à modelagem dos dados, envolvendo a construção das janelas temporais, a rotulagem das tendências e a divisão dos conjuntos de treinamento, validação e teste. A terceira envolve o treinamento da rede LSTM, a predição da tendência futura e a avaliação do desempenho do modelo.

4.1 Seleção dos ativos e coleta dos dados

A primeira etapa da metodologia consiste na seleção dos ativos financeiros utilizados no experimento. Como o objetivo deste trabalho está relacionado ao mercado brasileiro, serão considerados ativos negociados na B3. A seleção poderá incluir ações com alta liquidez e representatividade no Ibovespa, além do ETF BOVA11 como ativo representativo do comportamento agregado do índice.

A escolha dos ativos deve considerar critérios como disponibilidade de dados históricos, liquidez, representatividade no mercado brasileiro e continuidade das negociações ao longo do período analisado. Esses critérios buscam reduzir distorções causadas por baixa negociação, ausência de dados ou séries temporais incompletas.

Após a seleção dos ativos, será realizada a coleta dos dados históricos em frequência diária. Para cada ativo, serão obtidos os dados de abertura, máxima, mínima, fechamento e volume negociado, seguindo a estrutura OHLCV apresentada na Seção 2.1.

A coleta será feita a partir de bases públicas de dados financeiros, como o Yahoo Finance ([Yahoo Finance, 2026](#)). Também será considerado o uso do BovDB, conjunto de dados com preços de ações de empresas listadas na B3 entre 1995 e 2020 ([CARDOSO et al., 2022](#)), especialmente como fonte de apoio ou comparação para dados históricos do mercado brasileiro. A escolha da fonte final considerará a disponibilidade, a cobertura temporal e a consistência dos registros para o período analisado. Os dados serão organizados em formato tabular, contendo a data da negociação e os respectivos valores financeiros de cada ativo.

4.2 Pré-processamento dos dados

Após a coleta, os dados passarão por uma etapa de pré-processamento com o objetivo de prepará-los para o treinamento do modelo. Inicialmente, os registros serão organizados em ordem cronológica, respeitando a sequência temporal das negociações.

Também serão verificados valores ausentes, registros duplicados e inconsistências nos dados. Quando necessário, valores ausentes serão tratados por remoção ou preenchimento, conforme a quantidade e a posição das falhas na série temporal. Essa etapa busca evitar que erros na base prejudiquem o treinamento da rede neural.

Em seguida, os atributos numéricos serão normalizados conforme os conceitos apresentados na Seção 2.2.2, reduzindo diferenças de escala entre variáveis como preço e volume antes do treinamento da rede neural.

Além dos dados históricos originais, será calculado o retorno percentual do preço de fechamento, utilizado como uma das informações de entrada e também como base para a definição dos rótulos de tendência.

4.3 Construção das entradas do modelo

Os dados serão organizados em formato sequencial por meio de janelas temporais deslizantes, conforme apresentado na Seção 2.2.2, permitindo que a LSTM receba sequências ordenadas de observações históricas.

Cada janela temporal será formada por um conjunto de observações consecutivas dos dias anteriores. Essa sequência será utilizada como entrada para o modelo, enquanto a tendência futura do ativo será utilizada como saída esperada. Assim, para cada ativo, serão criadas amostras de treinamento a partir do deslocamento progressivo da janela ao longo da série temporal.

De forma geral, cada amostra será composta por uma matriz contendo os dados dos últimos (N) dias, em que (N) representa o tamanho da janela temporal definido para o experimento. A saída associada a essa amostra será a classe de tendência observada em um horizonte futuro.

A definição do tamanho da janela e do horizonte de predição será realizada durante a configuração experimental, considerando a quantidade de dados disponível e o comportamento dos ativos selecionados.

4.4 Rotulagem das tendências

A rotulagem das tendências será realizada a partir da formulação discutida na Seção 2.2.3. Neste trabalho, serão consideradas três classes de saída: alta, baixa e estabilidade. Essa formulação é coerente com estudos de predição de tendência de preços que tratam o problema como uma classificação entre movimentos de alta, baixa e estabilidade (PRATA et al., 2024).

A definição da classe será realizada a partir da variação percentual do preço de fechamento em um horizonte futuro. A variação será calculada comparando o preço de fechamento atual com o preço de fechamento futuro, conforme a Equação 4.1.

$$\text{variação} = \frac{\text{preço futuro} - \text{preço atual}}{\text{preço atual}} \quad (4.1)$$

Com base nessa variação, serão definidos limiares para classificar cada amostra. Quando a variação for superior ao limite positivo definido, a amostra será rotulada como alta. Quando a variação for inferior ao limite negativo definido, será rotulada como baixa. Caso a variação permaneça entre os dois limites, a amostra será classificada como estabilidade.

Os limiares utilizados na classificação serão definidos com base na análise exploratória dos dados, considerando a volatilidade dos ativos selecionados e a distribuição das classes geradas. Essa análise busca evitar rótulos excessivamente sensíveis a pequenas oscilações ou concentração exagerada de amostras em uma única classe.

4.5 Divisão dos dados

Após a construção das entradas e dos rótulos, os dados serão divididos em conjuntos de treinamento, validação e teste. Por se tratar de séries temporais financeiras, a divisão será feita de forma cronológica, sem embaralhamento dos registros, seguindo a lógica apresentada na Seção 2.2.2.

Os dados mais antigos serão utilizados para treinamento do modelo, uma parte intermediária será destinada à validação e os dados mais recentes serão reservados para teste. Essa estratégia busca simular uma situação próxima ao uso real, em que o modelo é treinado com dados passados e avaliado em dados futuros.

Neste trabalho, será adotada inicialmente a seguinte divisão: 70% dos dados para treinamento, 15% para validação e 15% para teste. O conjunto de treinamento será utilizado para ajuste dos pesos da rede neural. O conjunto de validação será utilizado para acompanhar o desempenho durante o treinamento e auxiliar no controle de sobreajuste. O conjunto de teste será utilizado apenas ao final, para avaliar o desempenho do modelo em dados não utilizados durante o treinamento.

4.6 Modelo LSTM

O modelo proposto neste trabalho será baseado em uma rede neural recorrente do tipo LSTM, cuja estrutura e adequação ao processamento de sequências temporais foram discutidas na Seção 2.2.1.1.1. A escolha dessa arquitetura é fundamentada em sua capacidade de lidar com dependências temporais em sequências, conforme proposto por Hochreiter e Schmidhuber (1997).

Na metodologia proposta, essa arquitetura será utilizada para classificar a tendência futura do ativo a partir das janelas temporais construídas. A arquitetura será mantida simples, com o objetivo de preservar a viabilidade do experimento e facilitar a análise dos resultados. O modelo será composto por uma camada de entrada, uma ou mais camadas

LSTM, uma camada de regularização do tipo Dropout, uma camada densa e uma camada de saída com função de ativação Softmax.

A camada de entrada receberá as janelas temporais construídas a partir dos dados históricos. A camada LSTM será responsável por processar a sequência temporal. A camada Dropout será utilizada para reduzir o risco de sobreajuste, conforme a técnica proposta por [Srivastava et al. \(2014\)](#). A camada densa realizará a combinação das representações aprendidas, e a camada Softmax produzirá uma distribuição de probabilidades entre as classes alta, baixa e estabilidade, sendo adequada para problemas de classificação multiclasse ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)).

A classe com maior probabilidade será considerada como a tendência prevista pelo modelo.

4.7 Treinamento do modelo

O treinamento será realizado utilizando o conjunto de treinamento definido na divisão cronológica dos dados. Como o problema é de classificação multiclasse, será utilizada uma função de perda adequada para esse tipo de tarefa, como a entropia cruzada categórica ou a entropia cruzada categórica esparsa, dependendo da codificação dos rótulos.

O otimizador Adam será utilizado para atualização dos pesos da rede, por ser um método de otimização baseado em taxas de aprendizado adaptativas ([KINGMA; BA, 2015](#)).

Durante os experimentos, serão configurados os principais hiperparâmetros do modelo, incluindo o tamanho da janela temporal, a quantidade de unidades LSTM, a taxa de dropout, o número de épocas, o tamanho do lote e a taxa de aprendizado. A escolha final desses valores será orientada pelo desempenho observado no conjunto de validação.

O conjunto de validação será utilizado para acompanhar a evolução do treinamento e identificar possíveis sinais de sobreajuste. Caso necessário, será aplicada a técnica de parada antecipada, interrompendo o treinamento quando o desempenho no conjunto de validação deixar de melhorar por um número determinado de épocas.

4.8 Predição e avaliação dos resultados

Após o treinamento, o modelo será aplicado ao conjunto de teste. Para cada janela temporal do conjunto de teste, a LSTM produzirá uma distribuição de probabilidades entre as três classes possíveis: alta, baixa e estabilidade.

A avaliação do desempenho será realizada por meio das métricas de classificação apresentadas na Seção 2.2.4. Devem ser consideradas principalmente acurácia, precisão,

recall e F1-score. Essas métricas serão utilizadas para avaliar o desempenho geral do modelo, o comportamento por classe e os principais tipos de erro cometidos na classificação das tendências.

Além da avaliação preditiva, os resultados poderão ser discutidos do ponto de vista de sua aplicabilidade prática. Como a saída do modelo representa uma tendência prevista, ela pode ser interpretada como um possível apoio à decisão de compra, venda ou manutenção. No entanto, a avaliação financeira será tratada como complementar, pois o foco principal deste trabalho é analisar a capacidade da LSTM em classificar tendências futuras de ações do mercado brasileiro.

4.9 Síntese da metodologia

A metodologia proposta consiste em coletar dados históricos de ativos do mercado brasileiro, realizar o pré-processamento das séries temporais, construir janelas temporais de entrada, rotular as tendências futuras em alta, baixa e estabilidade, treinar uma rede neural LSTM e avaliar seu desempenho por métricas de classificação.

A proposta busca verificar se uma arquitetura recorrente simples é capaz de aprender padrões temporais em dados históricos de ações brasileiras e utilizá-los para classificar a tendência futura dos ativos. A abordagem mantém o foco na viabilidade experimental, no uso de dados financeiros históricos e na avaliação objetiva do desempenho preditivo do modelo.

5 Resultados Esperados

O desenvolvimento deste trabalho busca alcançar resultados relacionados à aplicação de uma rede neural LSTM na predição de tendências em ações do mercado brasileiro. Como a proposta está voltada à classificação de movimentos futuros em alta, baixa ou estabilidade, espera-se avaliar a capacidade do modelo em identificar padrões temporais a partir de dados históricos financeiros.

Os resultados esperados deste trabalho podem ser organizados em diferentes aspectos, relacionados à organização e preparação dos dados, à rotulagem das tendências, ao desempenho do modelo LSTM, à análise da viabilidade da abordagem e às limitações esperadas.

5.1 Organização e preparação dos dados

Espera-se que, ao final da etapa de coleta e pré-processamento, seja construída uma base de dados organizada contendo informações históricas de ativos negociados na B3, incluindo ações que compõem o Ibovespa e o ETF BOVA11. Essa base deverá conter dados financeiros em frequência diária, como abertura, máxima, mínima, fechamento e volume negociado.

Também se espera que os dados sejam tratados de forma adequada para uso em modelos de aprendizado profundo. Isso inclui a organização cronológica das séries, o tratamento de valores ausentes ou inconsistentes, a normalização dos atributos numéricos e a construção de variáveis derivadas, como o retorno percentual do preço de fechamento.

Outro resultado esperado é a construção das janelas temporais deslizantes, que servirão como entrada para a rede LSTM. Essas janelas devem permitir que o modelo receba sequências de observações históricas e utilize essas informações para classificar a tendência futura do ativo.

5.2 Rotulagem das tendências

Espera-se que a metodologia de rotulagem permita transformar as variações futuras dos preços em três classes: alta, baixa e estabilidade. Essa etapa é fundamental para formular o problema como uma tarefa de classificação multiclasse.

A classe alta deverá representar situações em que o preço de fechamento apresenta variação positiva relevante em determinado horizonte futuro. A classe baixa deverá representar situações em que ocorre variação negativa relevante. Já a classe estabilidade deverá

representar casos em que a variação do preço permanece dentro de uma faixa intermediária, sem caracterizar uma tendência clara de alta ou de baixa.

Também se espera que a análise exploratória dos dados auxilie na definição dos limiares utilizados para a rotulagem. Esses limiares devem evitar que pequenas oscilações do mercado sejam interpretadas como tendências significativas, reduzindo a influência de ruídos nos rótulos gerados. Além disso, espera-se observar a distribuição das classes para verificar se há desbalanceamento entre alta, baixa e estabilidade.

5.3 Desempenho do modelo LSTM

Espera-se que a rede neural LSTM seja capaz de aprender padrões temporais presentes nos dados históricos dos ativos analisados. Como a LSTM é uma arquitetura voltada ao processamento de sequências, espera-se que ela consiga explorar informações contidas nas janelas temporais para realizar a classificação da tendência futura.

O desempenho do modelo será avaliado por meio de métricas de classificação, como acurácia, precisão, recall, F1-score e matriz de confusão. Espera-se que essas métricas permitam analisar não apenas o desempenho geral do modelo, mas também o comportamento individual em cada classe.

A acurácia deverá fornecer uma visão geral da proporção de classificações corretas. A precisão deverá indicar a confiabilidade das previsões feitas para cada classe. O recall deverá mostrar a capacidade do modelo de identificar corretamente os casos reais de alta, baixa e estabilidade. O F1-score deverá auxiliar na análise do equilíbrio entre precisão e recall, especialmente caso as classes apresentem distribuição desbalanceada.

A matriz de confusão deverá permitir uma análise mais detalhada dos erros cometidos pelo modelo. Por meio dela, espera-se identificar se a rede confunde com maior frequência determinadas classes, como estabilidade com alta ou estabilidade com baixa. Essa análise será importante para compreender as limitações do modelo e verificar quais tipos de tendência são mais difíceis de classificar.

5.4 Análise da viabilidade da abordagem

Espera-se que os experimentos permitam avaliar a viabilidade do uso de uma arquitetura LSTM simples para a predição de tendências em ações do mercado brasileiro. O objetivo não é demonstrar a superioridade definitiva da LSTM em relação a todas as arquiteturas existentes, mas verificar se essa abordagem é capaz de produzir resultados consistentes dentro do recorte definido neste trabalho.

Também se espera que o estudo contribua para a análise da aplicação de redes

neurais recorrentes em ativos negociados na B3, considerando que grande parte dos trabalhos relacionados analisados utiliza dados de mercados internacionais. Dessa forma, os resultados poderão indicar se a metodologia proposta é adequada para investigar padrões em séries temporais financeiras do mercado brasileiro.

Além disso, espera-se que a abordagem adotada permita uma avaliação experimental controlada, baseada em dados históricos, divisão cronológica dos conjuntos de treinamento, validação e teste, rotulagem multiclasse e métricas de classificação. Essa estrutura deverá permitir uma análise objetiva do desempenho do modelo.

5.5 Limitações esperadas

Apesar dos resultados esperados, reconhece-se que a predição de tendências no mercado financeiro é uma tarefa complexa. As séries temporais financeiras são influenciadas por diversos fatores externos, como eventos econômicos, políticos, setoriais e comportamentais, que nem sempre estão representados diretamente nos dados históricos de preço e volume.

Também se espera que o modelo possa apresentar dificuldades em períodos de maior volatilidade ou em situações de mudança brusca no comportamento do mercado. Além disso, a presença de ruído nos dados financeiros pode dificultar a identificação de padrões consistentes, afetando o desempenho da classificação.

Outra limitação esperada está relacionada à definição dos rótulos. A escolha dos limiares para classificar alta, baixa e estabilidade pode influenciar diretamente a distribuição das classes e, conseqüentemente, o desempenho do modelo. Por isso, a análise exploratória dos dados será importante para reduzir distorções na rotulagem.

Por fim, destaca-se que os resultados deste trabalho não devem ser interpretados como recomendação financeira ou estratégia de investimento. O objetivo é avaliar experimentalmente a aplicação de uma rede LSTM na classificação de tendências a partir de dados históricos, contribuindo para a discussão acadêmica sobre o uso de aprendizado profundo em séries temporais financeiras do mercado brasileiro.

6 Cronograma

Para assegurar a organização e a conclusão adequada deste trabalho, foi elaborado um cronograma com as principais etapas necessárias para o desenvolvimento da pesquisa. O planejamento contempla desde a revisão final dos capítulos teóricos até a implementação do modelo LSTM, realização dos experimentos, análise dos resultados e redação deste trabalho.

As atividades foram distribuídas ao longo do segundo semestre de 2026, considerando o período entre 3 de agosto e 5 de dezembro. Esse planejamento contempla as etapas de preparação dos dados, modelagem, treinamento, avaliação e escrita final do trabalho. A organização busca garantir que cada fase seja realizada de forma sequencial e controlada, respeitando a dependência entre as atividades. Por exemplo, a implementação e o treinamento do modelo dependem da conclusão da coleta, do pré-processamento e da rotulagem dos dados.

A Tabela 6 apresenta o cronograma previsto para a execução das atividades do trabalho.

Parte do Trabalho	Início	Fim	Duração (dias)
Revisão dos capítulos teóricos	03/08/2026	16/08/2026	14
Coleta dos dados históricos	17/08/2026	23/08/2026	7
Pré-processamento dos dados	24/08/2026	06/09/2026	14
Construção das janelas e rótulos	07/09/2026	20/09/2026	14
Implementação da rede LSTM	21/09/2026	04/10/2026	14
Treinamento e validação	05/10/2026	18/10/2026	14
Avaliação do modelo	19/10/2026	01/11/2026	14
Análise dos resultados	02/11/2026	15/11/2026	14
Redação dos resultados e conclusão	16/11/2026	29/11/2026	14
Revisão final e ajustes	30/11/2026	05/12/2026	6

Tabela 6 – Cronograma das atividades.

O cronograma proposto poderá sofrer ajustes ao longo do desenvolvimento do trabalho, especialmente durante as etapas experimentais. Como a predição de tendências em séries temporais financeiras envolve decisões relacionadas à escolha dos ativos, definição dos limiares de rotulagem, configuração das janelas temporais e ajuste dos hiperparâmetros, algumas atividades poderão demandar revisões ou repetições.

Mesmo assim, a divisão apresentada permite organizar o desenvolvimento deste trabalho em etapas bem definidas, facilitando o acompanhamento do progresso e a identificação de possíveis atrasos. Ao final do período planejado, espera-se que a implementação do modelo, a avaliação dos resultados e a redação final estejam concluídas.

7 Considerações Finais

Este trabalho apresenta uma proposta para a predição de tendências em ações do mercado brasileiro utilizando uma rede neural recorrente do tipo LSTM. A pesquisa parte da dificuldade existente na previsão de séries temporais financeiras, que são caracterizadas por volatilidade, ruído, não estacionariedade e influência de diversos fatores externos. Em vez de buscar prever diretamente o preço futuro de uma ação, este trabalho propõe tratar o problema como uma tarefa de classificação multiclasse, na qual os movimentos futuros dos ativos são classificados em alta, baixa ou estabilidade.

A proposta concentra-se em ativos negociados na B3, incluindo ações que compõem o Ibovespa e o ETF BOVA11. Essa escolha está relacionada à necessidade de estudos voltados ao mercado brasileiro, uma vez que grande parte dos trabalhos analisados na literatura utiliza dados de mercados internacionais, como Estados Unidos, China, Índia e outros mercados asiáticos. Dessa forma, este trabalho busca contribuir para a análise da aplicação de redes neurais em séries temporais financeiras brasileiras.

Ao longo do trabalho, foram apresentados os principais conceitos necessários para a compreensão da pesquisa, incluindo mercado de ações, séries temporais financeiras, predição de tendências, aprendizado de máquina, aprendizado profundo, redes neurais recorrentes, LSTM, classificação multiclasse e métricas de avaliação. Também foram discutidos trabalhos relacionados que utilizam redes neurais e técnicas de aprendizado profundo para predição de tendências, movimentos ou direção de preços no mercado de ações.

A metodologia proposta organiza o desenvolvimento do trabalho em etapas sequenciais. Inicialmente, serão selecionados os ativos e coletados os dados históricos. Em seguida, os dados passarão por pré-processamento, normalização e construção de janelas temporais. A rotulagem das tendências será realizada com base na variação percentual do preço de fechamento em um horizonte futuro, permitindo a definição das classes alta, baixa e estabilidade. Posteriormente, será implementada uma arquitetura LSTM para classificar as tendências futuras, e seu desempenho será avaliado por meio de métricas como acurácia, precisão, recall, F1-score e matriz de confusão.

Espera-se que a realização deste trabalho permita verificar a viabilidade do uso de uma arquitetura LSTM simples para a classificação de tendências em ações do mercado brasileiro. Os resultados obtidos poderão indicar se o modelo é capaz de aprender padrões temporais a partir de dados históricos e utilizá-los para classificar movimentos futuros dos ativos analisados. Além disso, a avaliação por métricas de classificação deverá permitir uma análise mais detalhada do desempenho do modelo em cada classe.

Como possíveis limitações, reconhece-se que o mercado financeiro é influenciado por fatores que nem sempre estão presentes nos dados históricos de preço e volume, como eventos econômicos, políticos, setoriais e comportamentais. Além disso, a definição dos limiares de rotulagem, o desbalanceamento entre classes, o tamanho da janela temporal e a escolha dos ativos podem influenciar diretamente os resultados obtidos. Por esse motivo, a análise dos resultados deverá considerar essas limitações.

Por fim, destaca-se que este trabalho não tem como objetivo propor uma estratégia de investimento ou recomendação financeira. O foco está na avaliação experimental da aplicação de uma rede LSTM na classificação de tendências a partir de dados históricos do mercado brasileiro. Como trabalhos futuros, poderão ser investigadas outras arquiteturas de aprendizado profundo, como GRU, CNN, Transformers e modelos híbridos, além da inclusão de indicadores técnicos, variáveis macroeconômicas ou informações setoriais para enriquecer a representação dos dados.

Referências

- B3. *Ações*. 2026. Disponível em: <https://www.b3.com.br/pt_br/produtos-e-servicos/negociacao/renda-variavel/acoes.htm>. Acesso em: 5 jun. 2026. Citado 2 vezes nas páginas 17 e 23.
- B3. *ETFs*. 2026. Disponível em: <https://www.b3.com.br/pt_br/produtos-e-servicos/negociacao/renda-variavel/etf/>. Acesso em: 5 jun. 2026. Citado na página 23.
- B3. *Ibovespa B3*. 2026. Disponível em: <https://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-amplos/ibovespa.htm>. Acesso em: 5 jun. 2026. Citado na página 23.
- B3. *Quem somos*. 2026. Site institucional da B3. Disponível em: <https://www.b3.com.br/pt_br/b3/institucional/quem-somos/>. Acesso em: 5 jun. 2026. Citado 2 vezes nas páginas 17 e 23.
- BISHOP, C. M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. Citado 4 vezes nas páginas 25, 26, 30 e 31.
- CARDOSO, F. C. et al. Bovdb: a data set of stock prices of all companies in b3 from 1995 to 2020. *Journal of Information and Data Management*, v. 13, n. 1, 2022. Citado na página 48.
- CHEN, Y. et al. Mstan: A multi-scale temporal attention network for stock prediction. *Information Sciences*, v. 733, p. 122992, 2025. Citado 7 vezes nas páginas 18, 38, 40, 41, 42, 43 e 44.
- GHOSH, I.; CHAUDHURI, T. D. Feb-stacking and feb-dnn models for stock trend prediction: a performance analysis for pre and post covid-19 periods. *Decision Making: Applications in Management and Engineering*, v. 4, n. 1, p. 51–86, 2021. Citado 6 vezes nas páginas 39, 40, 41, 42, 43 e 44.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016. Citado 8 vezes nas páginas 17, 27, 28, 29, 30, 31, 32 e 51.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. Citado 6 vezes nas páginas 17, 20, 27, 28, 29 e 50.
- HU, L.; SHEN, Y. A predictive analytics approach for forecasting global stock index returns using deep learning techniques. *Decision Analytics Journal*, v. 18, p. 100685, 2026. Citado 7 vezes nas páginas 18, 39, 40, 41, 42, 43 e 44.
- HUANG, Y.; CUI, K.; LU, X. Stock trading strategy based on multi-scale deep reinforcement learning and price movement prediction. *International Journal of Information Technology & Decision Making*, 2025. Citado 6 vezes nas páginas 39, 40, 41, 42, 43 e 44.
- KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: *International Conference on Learning Representations*. [S.l.: s.n.], 2015. Citado na página 51.

LATIF, S. et al. Enhanced prediction of stock markets using a novel deep learning model plstm-tal in urbanized smart cities. *Heliyon*, v. 10, p. e27747, 2024. Citado 6 vezes nas páginas 38, 40, 41, 42, 43 e 44.

MANJUNATH, C.; MARIMUTHU, B.; GHOSH, B. Deep learning for stock market index price movement forecasting using improved technical analysis. *International Journal of Intelligent Engineering and Systems*, v. 14, n. 5, p. 129–141, 2021. Citado 7 vezes nas páginas 18, 39, 40, 41, 42, 43 e 44.

MUHAMMAD, D. et al. An explainable deep learning approach for stock market trend prediction. *Heliyon*, v. 10, p. e40095, 2024. Citado 6 vezes nas páginas 37, 40, 41, 42, 43 e 44.

PADOVANI, M. R.; JUNIOR, J. R. B. A stock trading algorithm based on trend forecasting and time series classification. In: *Anais de evento*. [S.l.: s.n.], 2021. Citado 9 vezes nas páginas 18, 20, 36, 40, 41, 42, 43, 44 e 45.

PRATA, M. et al. Lob-based deep learning models for stock price trend prediction: a benchmark study. *Artificial Intelligence Review*, v. 57, p. 116, 2024. Citado 10 vezes nas páginas 17, 26, 32, 38, 40, 41, 42, 43, 44 e 49.

SINHA, S. et al. Sector influence aware stock trend prediction using 3d convolutional neural network. *Journal of King Saud University – Computer and Information Sciences*, v. 34, p. 1511–1522, 2022. Citado 7 vezes nas páginas 18, 37, 40, 41, 42, 43 e 44.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009. Citado 2 vezes nas páginas 32 e 33.

SRIVASTAVA, N. et al. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, v. 15, n. 56, p. 1929–1958, 2014. Citado 2 vezes nas páginas 30 e 51.

TIAN, H. et al. Graph representation learning of multilayer spatial-temporal networks for stock predictions. *IEEE Transactions on Computational Social Systems*, v. 12, n. 5, p. 2228–2240, 2024. Citado 7 vezes nas páginas 18, 37, 40, 41, 42, 43 e 44.

TSAY, R. S. *Analysis of Financial Time Series*. 3. ed. Hoboken: John Wiley & Sons, 2010. Citado 4 vezes nas páginas 17, 24, 25 e 30.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2017. v. 30. Citado na página 27.

XU, H. et al. Hrformer: A hybrid relational transformer for stock time series forecasting. *Electronics*, v. 14, n. 22, p. 4459, 2025. Citado 6 vezes nas páginas 38, 40, 41, 42, 43 e 44.

Yahoo Finance. *Yahoo Finance*. 2026. Disponível em: <<https://finance.yahoo.com/>>. Acesso em: 5 jun. 2026. Citado na página 48.

YOU, Z. et al. Multi-relational graph diffusion neural network with parallel retention for stock trends classification. In: *ICASSP 2024 – 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2024. p. 6545–6549. Citado 7 vezes nas páginas 18, 37, 40, 41, 42, 43 e 44.

ZU, Q. et al. Adv-shnets: a stock movement prediction framework based on hierarchy lstm networks. *International Journal of Data Science and Analytics*, v. 21, p. 29, 2026. Citado 6 vezes nas páginas [39](#), [40](#), [41](#), [42](#), [43](#) e [44](#).